

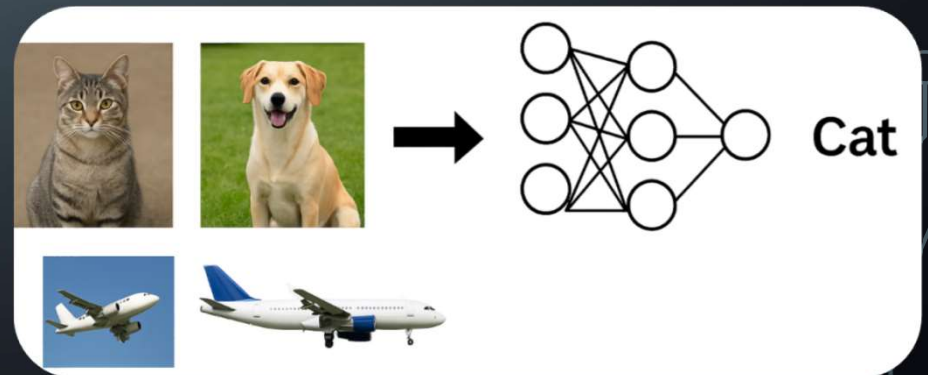
ANALIZA I BADANIE DZIAŁANIA WYBRANYCH SIECI NEURONOWYCH W ZADANIU KLASYFIKACJI OBRAZÓW NA ZBIORZE IMAGENET

AUTOR: MAREK SIGMUND

PROMOTOR PRACY: DR HAB. INŻ. PROF. PCZ KRYSTIAN ŁAPA

KLASYFIKACJA OBRAZÓW

- Klasyfikacja obrazów to jedno z najważniejszych zadań w dziedzinie przetwarzania danych wizualnych. Polega ono na przypisaniu wejściowego obrazu do jednej z wcześniej zdefiniowanych klas.
- Współcześnie najskuteczniejsze metody klasyfikacji opierają się na sztucznych sieciach neuronowych, a w szczególności na konwolucyjnych sieciach neuronowych (CNN).



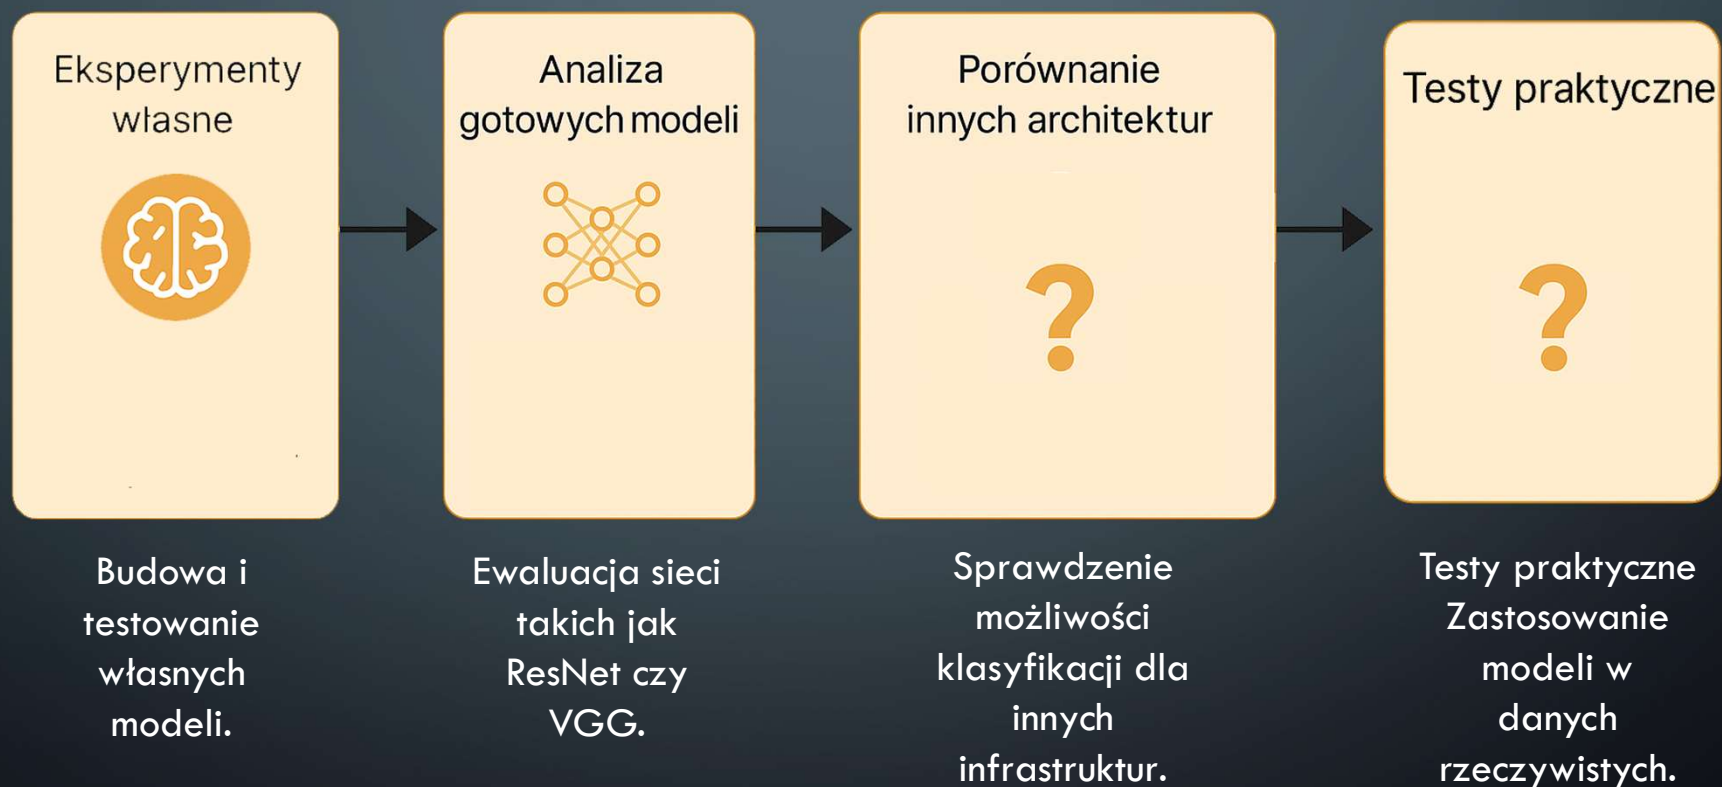
MOTYWACJA I CEL PRACY

- Motywacją do podjęcia tego tematu była chęć głębszego zrozumienia, jak konkretne decyzje projektowe – np. liczba warstw, typy funkcji aktywacji czy inne cechy architektury – wpływają na skuteczność, stabilność oraz wymagania obliczeniowe sieci neuronowej.
- Celem pracy jest zaprojektowanie modeli, które będą nie tylko skuteczne, ale też dobrze zbalansowane pod względem złożoności i możliwości praktycznego zastosowania. Badania obejmą zarówno sieci budowane od podstaw, jak i porównanie ich z gotowymi, zoptymalizowanymi architekturami.

ZBIÓR DANYCH

- **ImageNet** to jeden z najbardziej znanych i obszernych zbiorów danych wykorzystywanych w zadaniach klasyfikacji obrazów. Zawiera ponad 14 milionów obrazów przypisanych do ponad 20 000 kategorii, z czego około 1 000 klas stanowi podstawę benchmarku używanego w konkursie ILSVRC (ImageNet Large Scale Visual Recognition Challenge). Obrazy są wysokiej jakości, zróżnicowane tematycznie i często zawierają wiele obiektów.
- **Tiny ImageNet** to zredukowana wersja zbioru ImageNet, przygotowana z myślą o testowaniu modeli w warunkach ograniczonych zasobów.
 - **200 klas** (wybranych z pełnego ImageNet),
 - **64x64 px** obrazy (zamiast 224x224 px),
 - **500 zdjęć treningowych, 50 walidacyjnych i 50 testowych** dla każdej klasy.

STRUKTURA PRACY I ETAPY REALIZACJI

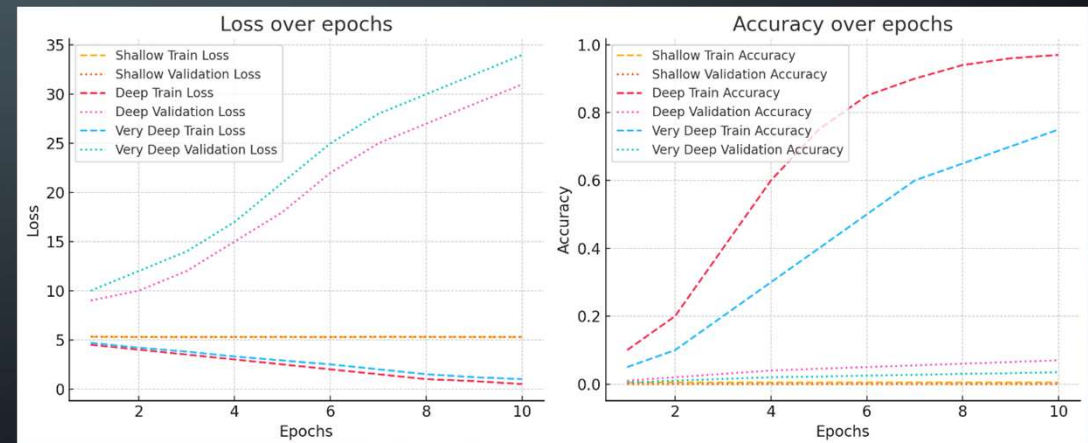


PIERWSZY ETAP EKSPERYMENTÓW

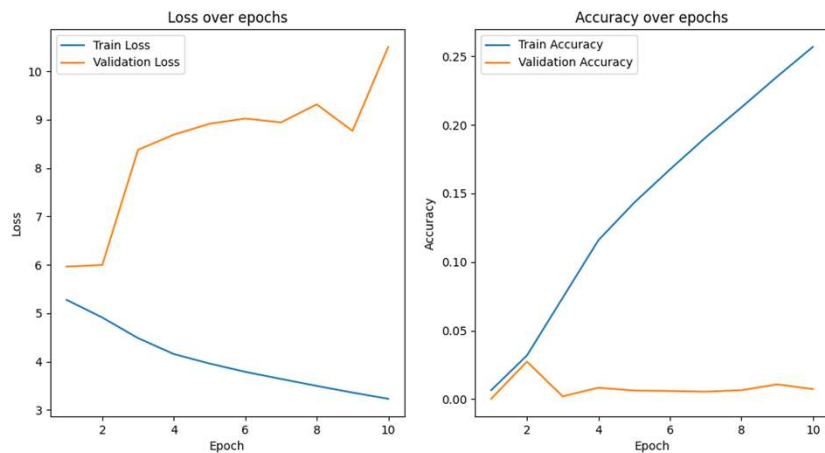
- **Celem pierwszej serii eksperymentów** było zbadanie stabilności działania modeli CNN przy różnych konfiguracjach. Na tym etapie dokładność odgrywała drugorzędną rolę skupiono się na stabilności modelu.

Przeanalizowano wpływ:

- liczby warstw konwolucyjnych i pełnych połączeń,
- problemu niedouczenia i przeuczenia,
- rodzaju funkcji aktywacji,
- różnych metod regularizacji,
- automatycznego doboru parametrów.



PRZEDSTAWIENIE WYNIKÓW



Wykres przedstawia przebieg uczenia modelu MediumCNN (7 warstw konwolucyjnych + MaxPool + 2 warstwy w pełni połączone), ujawniając przeuczenie – poprawę na zbiorze treningowym bez poprawy na walidacyjnym.

Model	Final Train Loss	Final Validation Loss	Final Train Accuracy	Final Validation Accuracy	Total Training Time (s)
Shallow CNN	0.3542	1.2458	62.13%	48.37%	524.6
Deep CNN	0.2107	0.8563	75.89%	61.42%	1246.8
Very Deep CNN	0.1523	0.7315	82.41%	68.92%	2894.3

Tabela przedstawia końcowe wyniki dla eksperymentu dotyczącego ilości warstw konwolucyjnych (2, 12, 27)

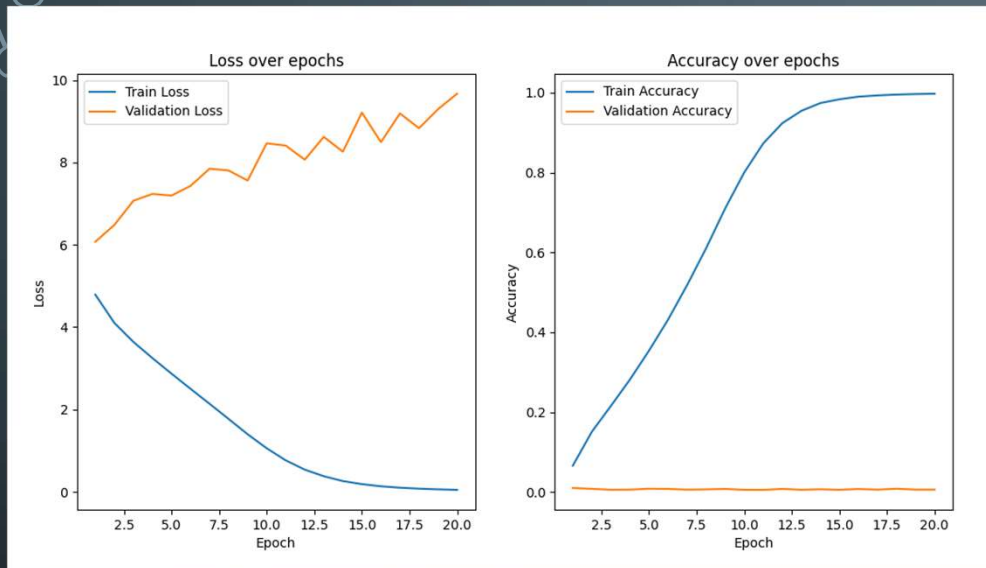
DRUGA SERIA EKSPERYMENTÓW

- Na podstawie wcześniej uzyskanych wyników zaprojektowano trzy modele sieci neuronowych o odmiennych strukturach.

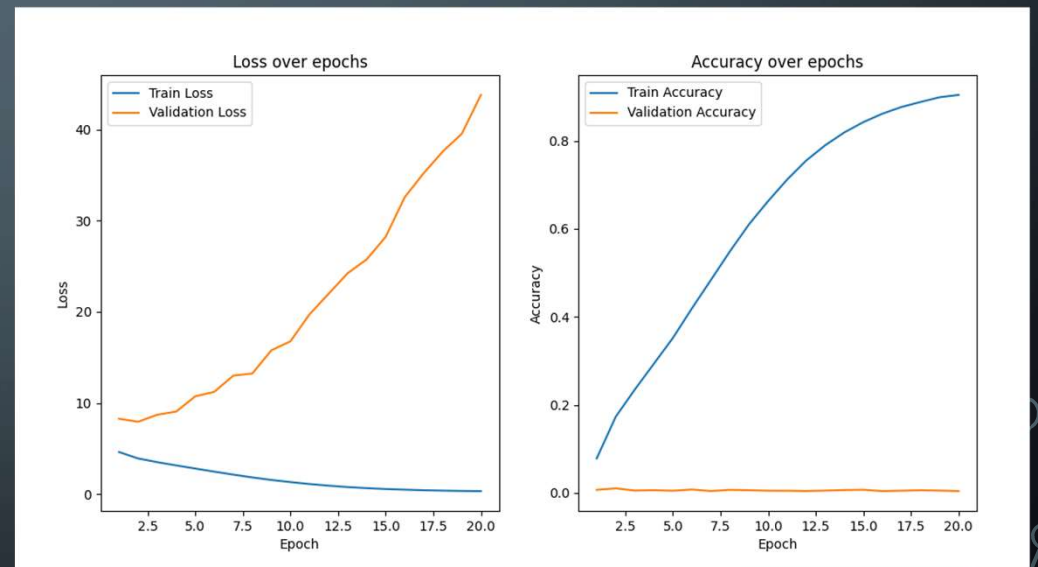
Druga seria eksperymentów dotyczyła wpływu:

- tempa uczenia (*learning rate*),
- wielkości partii (*batch size*),
- typu optymalizatora (np. Adam, SGD),
 - metod regularizacji,
 - augmentacji danych.

PREZENTACJA WYNIKÓW



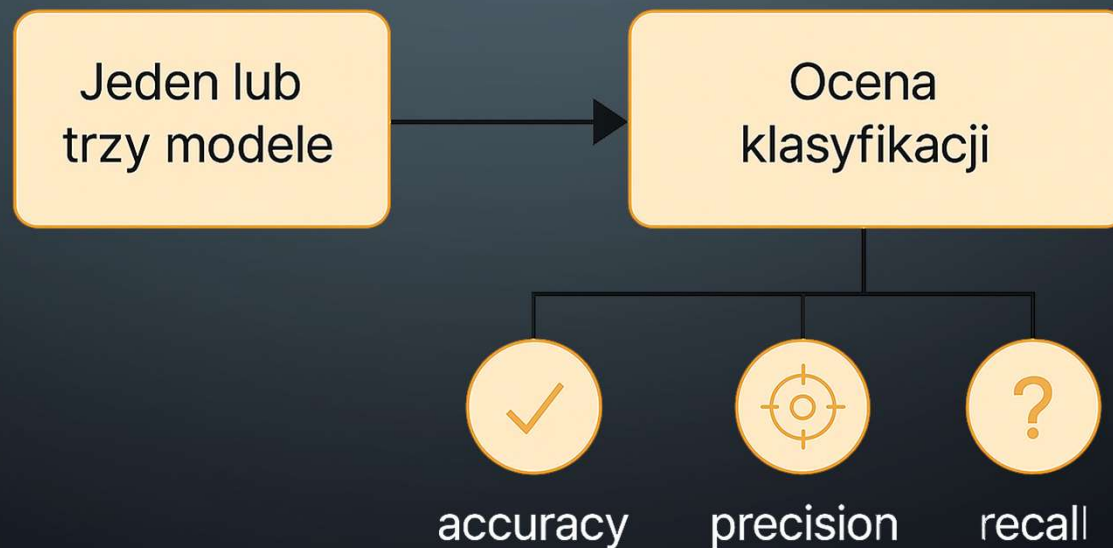
Model zbalansowany learning rate = 0.00001



Model słaby batch size = 64

FINALNE EKSPERYMENTY

- Na podstawie poprzednich badań powstanie jeden lub trzy modele, które zostaną dokładnie przetestowane w kolejnym etapie – już z użyciem klasycznych metryk oceny jakości klasyfikacji (np. accuracy, precision, recall).



ANALIZA GOTOWYCH MODELI

- W kolejnym etapie badań przeprowadzona zostanie analiza działania gotowych, popularnych architektur konwolucyjnych sieci neuronowych.

Wstępnie planowane do przetestowania modele:

- **VGG** – klasyczna, głęboka architektura oparta na prostych warstwach konwolucyjnych.
- **ResNet** – sieć z połączeniami rezydualnymi umożliwiającą trenowanie bardzo głębokich modeli.
- **EfficientNet** (opcjonalnie) – nowoczesna i zoptymalizowana architektura o wysokiej skuteczności przy stosunkowo niskich wymaganiach obliczeniowych.

ANALIZA GOTOWYCH MODELI

Analiza obejmuje:

- ocenę skuteczności modeli na wybranym zbiorze danych,
 - ewentualne douczanie klasyfikatorów (fine-tuning),
- porównanie wyników z wcześniej zbudowanymi modelami własnymi.

PORÓWNANIE INNYCH ARCHITEKTUR

- W ramach rozszerzenia eksperymentów planowane jest zbadanie możliwości klasyfikacji obrazów przy użyciu innych typów sieci neuronowych niż klasyczne konwolucyjne sieci CNN.

Rozważane kierunki:

- Sieci hybrydowe (np. CNN + RNN),
- Modele bazujące na transformatorach (np. **Vision Transformers – ViT**),
- Inne nietypowe lub lekkie architektury (np. **MobileNet**, **SqueezeNet**).

- Celem tej części będzie:
- sprawdzenie, jak alternatywne podejścia radzą sobie w zadaniu klasyfikacji obrazów,
 - ocena ich efektywności obliczeniowej i dokładności,
 - oraz porównanie ich z wynikami uzyskanymi wcześniej dla klasycznych modeli.

Zakres realizacji tej części będzie zależny od dostępnych zasobów i wyników wcześniejszych etapów.

TESTY PRAKTYCZNE

Na obecnym etapie testy praktyczne pozostają otwartym kierunkiem dalszych prac. Ich realizacja będzie uzależniona od dostępnego czasu oraz możliwości technicznych.

Planowane zastosowanie:

Wykorzystanie wytrenowanych modeli do klasyfikacji obrazów pochodzących z nagrań z samochodu badawczego uczelni.

- Tego rodzaju testy umożliwiłyby ocenę skuteczności modeli w rzeczywistych warunkach środowiskowych oraz potencjalną analizę ich przydatności w zastosowaniach takich jak rozpoznawanie obiektów w ruchu ulicznym.

AKTUALNY STAN PRAC

✓ Zrealizowane etapy:

- Przeprowadzono eksperymenty wstępne (analiza wpływu głównych parametrów sieci).
- Zbudowano i przetestowano trzy różne modele CNN na podstawie wcześniejszych wyników.
- Przeanalizowano wpływ takich elementów jak: *learning rate*, *batch size*, *optymalizator*, augmentacja danych i regularizacja.

🔧 Etapy w trakcie realizacji:

- Budowa i przygotowanie finalnych modeli do pełnych testów z metrykami jakości klasyfikacji.
- Rozpoczęcie testowania gotowych architektur

An abstract graphic on the left side of the slide, consisting of a network of thin, light blue lines and small circles, resembling a circuit board or a neural network diagram. The lines and circles are arranged in a vertical, branching pattern, extending from the top to the bottom of the frame.

DZIĘKUJE ZA UWAGĘ